

AI 자체 팩트체크 기능 설명

추출한 사건 정보를 AI가 스스로 원문과 대조해서 검증하는 기능 · 2026-08-08

1. 왜 필요했나


문제 1. AI가 뉴스에서 "이 사건이 진짜 일어났다"고 추출할 때, 그 판단 근거를 **자기 자신이 자기 주장에 스스로 한 줄 적어놓는 것**뿐이었다. 다른 검사 없이 그대로 믿고 서비스에 노출됐다.

문제 2. 화면에 "이 사건의 근거가 된 사실들", "출처 목록"을 보여주는 기능이 이미 설계는 돼 있었지만, 실제로 그 데이터를 채워 넣는 코드가 없어서 **항상 빈 화면**으로 나가고 있었다.

2. 무엇을 만들었나

기존 추출 단계 뒤에 **검증 전용 2차 AI 호출**을 추가했다. 이 호출의 역할은 "새로운 걸 알아내는 것"이 아니라, **방금 나온 결과가 원문에 실제로 있는 내용인지 하나하나 확인하는 것**뿐이다 — 사람으로 치면 "취재기자"와 "데스크(팩트체커)"를 분리한 것과 같다.

3. 어떻게 동작하나



파란색(3번)이 이번에 새로 추가된 단계

4. 예시로 보면

1단계 · AI 추출 결과

"부산에서 대규모 야외 콘서트가 열려 10만 명이 방문했고, 티켓이 전량 매진됐다."

2단계 · AI 검증 결과 (원문과 하나씩 대조)

사실 부산에서 야외 콘서트가 열렸다 — 원문에 명시됨

사실 10만 명이 방문했다 — 원문에 명시됨

불일치 티켓이 전량 매진됐다 — 원문에 언급 없음 (AI가 지어냄)

사실 2개는 근거 화면에 노출, 근거 없는 주장 1개는 걸러짐 → 이벤트 신뢰도는 "일부 미확인(DISPUTED)"으로 표시

5. 기존 방식과 무엇이 다른가

	기존	신규
검증 주체	추출한 AI가 자기 주장에 스스로 확신도를 붙임	별도 호출이 원문과 대조하는 독립된 감사(audit)
판정 단위	사건 전체에 근거 문장 1개	사실을 여러 개로 쪼개 항목별로 참/거짓 판정
화면 노출	근거/출처 화면이 항상 빈 화면	실제 검증된 사실/출처가 채워짐
신뢰도 표시	사실상 항상 "미검증" 고정	검증 결과에 따라 "검증됨"/"일부 미확인"으로 갈림
실패 시	-	검증이 실패해도 이벤트 생성 자체는 그대로 유지 (안전장치)

한 줄 요약 · AI가 "이런 일이 있었다"고 말하는 것과, 그 말이 진짜인지 AI 스스로 다시 확인하는 것은 다르다 — 이번 기능은 그 확인 절차를 실제로 만들어서, 지금까지 비어있던 "근거/출처" 화면과 "신뢰도" 표시를 처음으로 실제 데이터로 채운다.